

SVD

2015年7月27日 星期一 下午10:34

第二次看，理解：

一、简介

是一种矩阵的变换，与矩阵的特征值分解类似。

矩阵的特征值分解是仅仅对方阵的一种分解，分解成比较好理解、表示、做一些事情的形式。

奇异值分解针对所有的矩阵都可以做，分解成好理解的形式。

二、特征值分解/矩阵的特征分解

目的是将矩阵(仅适用于方阵)，用一种方式更形象、好理解的方式描述。

1、线性变换


首先，矩阵可以用来做线性变换，例如

$$M = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

从几何的角度，矩阵可以描述为一个变换：用矩阵乘法将平面上的点 (x, y) 变换成另外一个点 $(3x, y)$ ：

$$\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3x \\ y \end{bmatrix}.$$


这种变换的效果如下：平面在水平方向被拉伸了3倍，在竖直方向无变化。



再如，

$$M = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

它会产生如下的效果



不过这张图貌似也并没有能够简洁、清晰的描述出上述矩阵变换的几何效果。然而，

我们能看出来，矩阵右乘一个向量可以做到，对这个向量线性变换，也就是在向量所在的空间进行拉伸变换。

出的里所出的上内延得拉伸时又比。

还能看出，不同的矩阵对不同的向量有不同形式的拉伸，有的只在一个方向上拉伸，有的是多个方向上。

为什么会这样，这是和矩阵本身、向量本身有关

2、特征值分解

a) 特征向量、特征值

任何一个方阵 M ，都存在一个正交向量组 v ，使得 v 里面的每个向量 v_i ，都满足：

$$Mv_i = \lambda_i v_i$$

其中， λ_i 是个常量，如果方阵 M 是 n 维的，这个向量组就有 n 个这样的向量

正交向量组的含义是，这是一组向量，而不是一个向量，这一组向量两两之间是正交的。

正交我们可以理解为，就像坐标轴一样，是两个不同的方向，互不干扰。

一个严格的说法是，正交向量组中的所有向量是线性无关的(线性独立)

v_i 叫做 M 的特征向量， λ_i 叫做 M 的特征值

b) 特征值分解/矩阵的特征分解

将 $Mv_i = \lambda_i v_i$ 中的 n 个 $v_i(i=1,2,3,\dots,n)$ 写在一起，写成在一个矩阵中就形成

$$A = Q\Sigma Q^{-1}$$

Q 中就包含 n 个向量 $v_i(i=1,2,3,\dots,n)$

这个就是特征值分解/矩阵的特征分解

这里 Q 是由 M 的 n 个特征向量组成的矩阵

c) 特征值分解数学含义的理解

结合1) 线性变换里面的内容考虑一下，特征值分解的数学含义，为什么这样分解，为什么一定存在特征向量和特征值？

不同的矩阵对不同的向量 v_i 有不同形式的拉伸，有的只在一个方向上拉伸，有的是多个方向上。

为什么会这样，这是和矩阵 M 本身、向量 v_i 本身有关，矩阵是对向量的一种线性变换，某个向量的方向比较巧的时候，这个线性变换做完以后只是在这个向量 v_i 的基础上做一个拉伸(不会更改方向，比如第一个例子。

我的理解是：这个矩阵所代表的 n 维空间上的线性变换(也可能不到 n

维，但是肯定 $\leq n$ 维)，是作用与 n 个线性独立的方向上的(方向数有可能 $\leq n$ ，我们暂认为是 n ，不影响什么)，可以理解为2、3维空间的坐标轴

由于向量 v_i 的特殊性，他所指示的方向，正好在"坐标轴"上，这样这个向量 v_i ，做完矩阵 M 的线性变换之后，只会被做拉伸操作。

反过来，我们可以通过哪些向量满足“只被做了拉伸操作”来确定这个向量指示的方向是不是矩阵 M 的 n 个独立的方向之一。

“只被做了拉伸操作”

也就是满足，经过 M 的变换之后，相当于在向量的基础上乘一个常数。

也就是满足 $Mv_i = \lambda_i v_i$

“这个向量指示的方向是不是矩阵 M 的 n 个独立的方向之一”

也就是这个向量是不是特征向量

如果是的话，我们就找出了这 n 个特征向量，这 n 个特征向量，指示了 M 变换的 n 维空间，特征值 λ_i 是每个方向上拉伸的长度

特征值越大，代表包含的信息越多，越是主要的方向，降维的时候，这个方向越会被保留

我的理解是，特征值分解之后的结果，是找出了一个方阵中(如果做线性变换的话)的方向，这叫做特征向量，也找出了在各个特征向量下拉伸的程度，这就是特征值。

d) 应用

可以用来做降维等。

三、奇异值分解

1、定义

特征值分解只能对方阵做，所以提出奇异值分解，类似特征值分解

也是转化成三个矩阵的乘积，也是两个正交的矩阵中间夹着一个类似对角阵(但不是)的矩阵

$$A = U \Sigma V^T$$

假设 A 是一个 $N * M$ 的矩阵，那么得到的 U 是一个 $N * N$ 的方阵（里面的向量是正交的， U 里面的向量称为左奇异向量）， Σ 是一个 $N * M$ 的矩阵（除了对角线的元素都是0，对角线上的元素称为奇异值）， V' （ V 的转置）是一个 $N * N$ 的矩阵，里面的向量也是正交的， V 里面的向量称为右奇异向量）

2、推导

借鉴特征值分解的方法，先 $A^T A$ 转成一个方阵，然后先求 $A^T A$ 的特征向量和特征值

$$(A^T A)v_i = \lambda_i v_i$$

继续推导

$$\sigma_i = \sqrt{\lambda_i}$$

$$u_i = \frac{1}{\sigma_i} A v_i$$

3、降维

同特征值分解的道理，对 λ_i (拉伸量的度量)排序，取top。
维度也降维r

$$\begin{matrix} A \\ m \times n \end{matrix} = \begin{matrix} U \\ m \times m \end{matrix} \times \begin{matrix} \Sigma \\ m \times n \end{matrix} \times \begin{matrix} V^T \\ n \times n \end{matrix}$$

转为:

$$\begin{matrix} A \\ m \times n \end{matrix} = \begin{matrix} U \\ m \times r \end{matrix} \times \begin{matrix} \Sigma \\ r \times r \end{matrix} \times \begin{matrix} V^T \\ r \times n \end{matrix}$$

四、参考资料:

不错的博客: <http://www.cnblogs.com/LeftNotEasy/archive/2011/01/19/svd-and-applications.html>

wiki: <https://zh.wikipedia.org/wiki/%E5%A5%87%E5%BC%82%E5%80%BC%E5%88%86%E8%A7%A3>

详细的英文博客: <http://www.ams.org/samplings/feature-column/fcarc-svd>

上面的英文博客的译文：<http://www.flickering.cn/%E6%95%B0%E5%AD%A6%E4%B9%8B%E7%BE%8E/2015/01/%E5%A5%87%E5%BC%82%E5%80%BC%E5%88%86%E8%A7%A3%E7%BC%88we-recommend-a-singular-value-decomposition%E7%BC%89/>

第一次看（Ng的课）：

一,简介

SVD是对一般的矩阵 $m \times n$, 进行分解的, 可以将任意一个矩阵, 分解成三个矩阵相乘的形式,

$$C = U \Sigma V^T$$

其中 $U \Sigma V$ 都有着一定的性质, 他们的组合也有着一定的性质

Ng说是用的最广泛的一种分解, 很常用的一种变换, SVD是LSA的数学基础.

二, 适用范围

矩阵分解的概念

矩阵分解是仅仅针对方阵的, 可以将方阵分解为三个矩阵相乘, 详见 参考资料1 中的讲解

奇异值分解作为矩阵分解的补充, 对任何矩阵都可以做

三, 形式

$$M = U \Sigma V^*$$

其中 U 是 $m \times m$ 阶酉矩阵; Σ 是半正定 $m \times$

n 阶对角矩阵; 而 V^* , 即 V 的共轭转置, 是 $n \times n$ 阶酉矩阵。

Σ 对角线上的元素 Σ_{ii} 即为 M 的奇异值。有大小顺序的, 我们可以把奇异值排个序选 top K 什么的以达到降维的目的

注意: 1. U 是方阵 本作者LSA中的SVD写错了 2. Σ 中 非零元素的个数可以自己控制 不受 m 和 n 的限制 (见wiki, Ng上例子)

四. 性质

性质 1

$$M^* M = V \Sigma^* U^* U \Sigma V^* = V (\Sigma^* \Sigma) V^*$$

$$M M^* = U \Sigma V^* V \Sigma^* U^* = U (\Sigma \Sigma^*) U^*$$

这个性质在LSA中用到了

性质2

V 的列向量（右奇异向量）是 $M^* M$ 的特征向量。

U 的列向量（左奇异向量）是 $M M^*$ 的特征向量。

Σ 的非零对角元（非零奇异值）是 $M^* M$ 或者 $M M^*$ 的非零特征值的平方根。

五. 实现

在openCV上有实现, 提供了python, MATLAB接口等

```
void cvSVD( CvArr* A, CvArr* W, CvArr* U=N_1, CvArr* V=N_1, int flags=0 )
```

void svdvd(CV_Mat_&A, CV_Mat_&U, CV_Mat_&SING, CV_Mat_&V, int flags=0);

六,应用

1, 做PCA

Ng哥在公开课的第15讲 中说了 大概在18~20min的地方,SVD 可以用在PCA中, 当PCA的维度过高时.

PCA中需要用到的协方差矩阵 $\Sigma = \frac{1}{n} \sum (x_i * x_i)$ 矩阵中对位相乘之后进行相加 用矩阵的形式就可以表示成 $\Sigma = X^T * X$

可以对X 进行SVD分解 $X = U * D * V$ 由于 SVD分解中U V 是正定矩阵 所以 $X^T * X$ 的时候 U 就可以消掉了

$\Sigma = V^T * D^2 * V$ 这个计算维度就低了吧

(但为啥高维的时候SVD可以用 这个还没想明白)

2,LSA (latent semantic analyse)

潜在语义分析,详见另一篇笔记

七,参考资料:

- 1 <http://blog.csdn.net/wangran51/article/details/7408414> SVD 不错
- 2 <http://blog.csdn.net/wangran51/article/details/7408406> 在LSA上应用
- 3 http://blog.sina.com.cn/s/blog_4b16455701016aaau.html 奇异值与特征值关系 :除 了一般性的定义 文章里说了句: 奇异值是 $A * A^H$ (A的 共轭转置)的特征值的平方根
- 4 <http://baike.baidu.com/view/3068725.htm?fr=aladdin>
- 5 <http://zh.wikipedia.org/wiki/%E5%A5%87%E5%BC%82%E5%80%BC%E5%88%86%E8%A7%A3> 比较详细 有些总结出来的性质不错 建议多看!